

Data Engineering Basic

CHAPTER 01 – DATA ENGINEERING OVERVIEW

www.dnastudio.co.id

2026

Daftar Isi

Data Engineering.....	2
Kebutuhan akan Data Engineer	3
Standar Gaji di Indonesia (Estimasi 2026)	3
Kegiatan Utama Data Engineer	4
Metoda Pengolahan Data	5
ETL vs ELT	5
Profesi Lain di Bidang Data	5
A. Data Analyst (Penerjemah Data)	5
B. Data Scientist (Peramal Data)	6
C. Data Architect (Perancang Strategi)	6
D. Database Administrator / DBA (Penjaga Gerbang)	6
E. Analytics Engineer (Jembatan)	6
Gambaran Alur Kerja.....	7
Data Engineer dalam Project	8
Data dan Informasi.....	8
Definisi Menurut Para Ahli.....	9
Perubahan Data Menjadi Informasi.....	10
Klasifikasi Data	10
Kualitas Informasi	11
Perbedaan Singkat: Data vs Informasi	11
Penyimpanan Data.....	12
Database	12
Metoda Penyimpanan Data	14
Macam Arsitektur dalam Penyimpanan Data.....	14
Metoda Klasik dan Modern.....	15
Tokoh dalam Data Architecture	15
Perbandingan Data Warehouse Vs Medallion	17


Data Engineer

01

Data engineer adalah *software engineer* yang membangun dan memelihara infrastruktur, *pipeline*, dan sistem yang mengumpulkan, menyimpan, dan mengubah “data mentah” menjadi informasi yang dapat digunakan. Mereka berperan sebagai fondasi bagi tim *data science*, memastikan data bersih, andal, dan mudah diakses untuk analisis, AI, dan pengambilan keputusan bisnis.

Data Engineering


Data Engineering adalah praktik praktis untuk mengumpulkan, memvalidasi, dan menyiapkan data dari berbagai sumber agar bisa digunakan oleh orang lain (seperti *Data Analyst*, *Data Scientist*, Analis Bisnis atau pihak lainnya yang berkepentingan).



shutterstock.com · 2573111765

Kebutuhan akan Data Engineer

Mengacu pada sebuah situs Job Technology, kebutuhan akan profesi *Data Engineer* masih bisa dikatakan yang tertinggi untuk dibidang IT, seperti terlihat dari diagram di bawah



[Source: Dice 2020 Tech Job Report](#)

Dengan demikian, peluang kita untuk berprofesi menjadi seorang *Data Engineer* masih cukup terbuka lebar. Hanya saja untuk menjadi seorang *Data Engineer* dibutuhkan sejumlah keahlian yang harus dimiliki.

Pada pembahasan selanjutnya akan dibahas sejumlah keahlian atau *skill* yang minimal harus dimiliki seorang *Data Engineer*.

Standar Gaji di Indonesia (Estimasi 2026)

Gaji sangat bergantung pada lokasi (Jakarta vs Bandung vs Remote) dan skala perusahaan (Startup vs Multinational). Berikut perkiraan gaji seorang *data engineer* **

** Ketentuan berlaku

Level Pengalaman	Rentang Gaji per Bulan (Gross)	Keterangan
Junior (0-2 thn)	Rp 10.000.000 s.d. Rp 18.000.000	Fokus pada SQL, ETL dasar, dan <i>maintenance</i> .
Mid-Level (2-5 thn)	Rp 22.000.000 s.d. Rp 45.000.000	Sudah menguasai arsitektur (seperti Medallion), Python, dan Cloud.
Senior (>5 thn)	Rp50.000.000 s.d. Rp 90.000.000+	Fokus pada desain sistem, strategi data, dan <i>cost optimization</i> .
Remote (Luar Negeri)	Rp80.000.000 s.d. Rp180.000.000+	Biasanya untuk perusahaan Singapura, Australia, atau AS.

Standar Kebutuhan Skill

Keahlian yang harus dipelajari dan dimiliki seorang *data engineer* dari sudut pandang segment tools yang digunakan antara lain:

1. **SQL:** Bahasa wajib untuk memanipulasi data di dalam database.
2. **Python:** Untuk otomatisasi dan menangani data yang tidak terstruktur.
3. **Cloud Platforms:** Memahami cara kerja penyimpanan di awan (Azure, AWS, atau Google Cloud).
4. **Pemahaman Infrastruktur:** Mengenal Docker atau Virtualisasi untuk menjalankan aplikasi pengolah data secara stabil.

Jika dilihat dari sudut pandang lainnya, seorang *data engineer* harus memiliki keahlian sebagai berikut :

1. **Core:** SQL (Advanced) dan Python tetap menjadi raja. Penguasaan *Window Functions* dan efisiensi memori di Python adalah wajib.
2. **Orchestration:** Airflow masih memimpin, namun kemampuan mengelola *event-driven orchestration* (seperti AWS Lambda atau Snowflake Tasks) semakin dicari.
3. **Data Modeling:** Memahami *Medallion Architecture* (Bronze, Silver, Gold) dan dbt (*data build tool*) untuk transformasi data.
4. **Cloud Native:** Pengalaman spesifik di salah satu *cloud* (AWS/GCP/Azure) dengan fokus pada manajemen izin (IAM) dan keamanan data.

Bahasa Pemrograman Baru: Golang (Go) mulai banyak digunakan untuk sistem data berperforma tinggi atau pembuatan alat *custom* di sisi infrastruktur.

Kegiatan Utama Data Engineer

Tahapan yang biasanya dilakukan oleh seorang *data engineer* adalah:

1. **Data Ingestion (Pengambilan Data):** Menarik data dari database aplikasi, API, atau sensor IoT secara rutin (batch) atau langsung (streaming).
2. **Data Transformation (Pengolahan):** Menulis skrip (biasanya SQL atau Python) untuk mengubah data kotor menjadi format yang rapi sesuai dengan *Data Model* yang sudah kita bahas tadi.



3. **Data Orchestration (Penjadwalan):** Memastikan proses pembersihan data berjalan otomatis setiap jam atau setiap hari tanpa harus dijalankan manual. (Contoh tool: Airflow).
4. **Data Quality & Monitoring:** Memastikan data yang masuk tidak rusak. Jika ada data yang hilang atau salah format, sistem akan memberi peringatan.

Metoda Pengolahan Data

Dalam pengolahan data digunakan beberapa metoda agar proses pengolahan dapat berjalan sesuai dengan yang direncanakan dan diinginkan. Pada umumnya metoda pengolahan data yang digunakan pada saat ini adalah terbagi menjadi dua (2) metoda yaitu *Extract Transform Load* dan *Extract Load Transform*.



ETL vs ELT

- **ETL (Extract, Transform, Load):**
 - Data diambil → Diubah/Dibersihkan di memori → Baru dimasukkan ke gudang data.
 - *Kapan digunakan?* Ketika gudang data Anda memiliki kapasitas terbatas atau ada aturan privasi ketat (data harus disensor sebelum disimpan).
- **ELT (Extract, Load, Transform):**
 - Data diambil → Langsung dimasukkan ke gudang data mentah → Baru diubah menggunakan kekuatan komputasi gudang data tersebut.
 - *Kapan digunakan?* Arsitektur modern (seperti Snowflake atau BigQuery) biasanya menggunakan ELT karena lebih cepat dan fleksibel.

Profesi Lain di Bidang Data

Untuk memudahkan peserta, Anda bisa membagi profesi lain berdasarkan apa yang mereka lakukan terhadap data yang sudah disiapkan oleh Data Engineer:

A. Data Analyst (Penerjemah Data)

Mereka adalah orang yang mengambil data yang sudah rapi untuk mencari tren dan pola, lalu menyajikannya dalam bentuk grafik yang mudah dimengerti oleh pimpinan perusahaan.

- **Tugas:** Menjawab pertanyaan bisnis seperti "*Berapa kenaikan penjualan bulan ini?*"
- **Tools:** SQL, PowerBI, Tableau, Excel.

B. Data Scientist (Peramal Data)

Mereka menggunakan data untuk membuat model prediksi atau algoritma cerdas (AI). Jika Data Analyst melihat masa lalu, Data Scientist mencoba melihat masa depan.

- **Tugas:** Menjawab pertanyaan seperti *"Pelanggan mana yang kemungkinan besar akan berhenti berlangganan bulan depan?"*
- **Tools:** Python, R, Machine Learning, Statistik.

C. Data Architect (Perancang Strategi)

Jika Data Engineer adalah pembangunnya, Data Architect adalah orang yang menggambar denah besarnya. Mereka menentukan teknologi apa yang akan digunakan secara keseluruhan di perusahaan.

- **Tugas:** Merancang visi jangka panjang arsitektur data agar tetap bisa berkembang 5-10 tahun ke depan.
- **Tools:** Data Modeling tools, Diagram Arsitektur.

D. Database Administrator / DBA (Penjaga Gerbang)

Fokus mereka adalah pada kesehatan dan keamanan database operasional. Mereka memastikan database tidak pernah mati (*down*) dan hanya orang berwenang yang bisa mengaksesnya.

- **Tugas:** Backup data, pengaturan hak akses, dan optimasi performa database.
- **Tools:** Oracle, SQL Server, PostgreSQL.

E. Analytics Engineer (Jembatan)


Ini adalah peran modern yang berada di antara Data Engineer dan Data Analyst. Mereka fokus pada pembersihan data di dalam gudang data menggunakan alat seperti **dbt**.

Tugas: Memastikan logika bisnis (seperti rumus "Pendapatan Bersih") konsisten di semua laporan.

Gambaran Alur Kerja

Secara singkat, alur kerja dalam pengolahan data kurang lebih seperti di bawah:

1. **Data Engineer:** Mengambil data mentah dari aplikasi.
2. **Data Architect:** Memastikan cara pengambilan data tersebut sesuai standar perusahaan.
3. **Analytics Engineer:** Merapikan data mentah tersebut agar mudah dibaca.
4. **Data Analyst:** Membuat laporan dari data yang sudah rapi untuk manajer.
5. **Data Scientist:** Menggunakan data tersebut untuk membuat sistem rekomendasi otomatis.




Tabel Perbandingan Profesi Data

Profesi	Fokus Utama	Skill Teknis Kunci	Output Utama
Data Engineer	Infrastruktur & Aliran Data	Python, SQL, Cloud, Airflow, Docker	Pipa Data (Pipeline) & Database yang Stabil
Data Analyst	Wawasan Bisnis & Tren	SQL, Excel, PowerBI/Tableau	Dashboard & Laporan Analisis
Data Scientist	Prediksi & Optimasi	Python/R, Statistik, Machine Learning	Model Prediksi & Algoritma AI
Data Architect	Struktur & Strategi	Data Modeling, Desain Sistem, Tata Kelola	Blueprint/Denah Arsitektur Data
Database Admin	Keamanan & Performa	Oracle, SQL Server, Backup/Recovery	Database yang Aman & Cepat

Data Engineer dalam Project

Posisi *data engineer* dalam sebuah project dapat tergambarkan pada sebuah diagram di bawah:



Dalam sebuah Project, Data Engineer fokus pada pembuatan dan penerapan solusi data yang efisien. Tanggung jawabnya meliputi:

1. **Dimensional Modeling:** Merancang schema Data Warehouse & Data Mart untuk mendukung kebutuhan analisis dan pelaporan
2. **Physical Design:** Menerapkan hasil modeling ke dalam arsitektur database, mengoptimalkan penyimpanan, dan konfigurasi Server untuk memastikan kinerja dan memiliki skalabilitas yang tinggi.
3. **ETL Design & Development:** Membangun dan memelihara ETL untuk mengekstrak, memanipulasi, dan Memuat data dari berbagai sumber ke dalam Data Warehouse, memastikan kualitas, integritas, dan ketersediaan data.


Data dan Informasi

Data secara bahasa berasal dari bahasa Latin yaitu *datum* yang berarti "sesuatu yang diberikan". Dalam konteks modern, data adalah sekumpulan informasi mentah (fakta, angka, karakter, atau simbol) yang belum memiliki makna sebelum diolah.

dan ...

Informasi adalah data yang telah diolah, diorganisir, dan ditempatkan ke dalam sebuah konteks sehingga memiliki makna dan nilai bagi penerimanya.

Informasi berfungsi untuk **mengurangi ketidakpastian** dan membantu dalam pengambilan keputusan.



Definisi Menurut Para Ahli

Data

Jogiyanto Hartono (Pakar Sistem Informasi Indonesia)

Menurut Jogiyanto, data adalah kenyataan yang menggambarkan suatu kejadian-kejadian dan kesatuan nyata. Kejadian tersebut adalah sesuatu yang terjadi pada saat tertentu.

Poin Penting: Data adalah representasi dari sebuah kejadian nyata (fakta).

Bernard Williams (Filsuf & Pakar Informasi)

Williams mendefinisikan data sebagai fakta mentah atau rincian peristiwa yang belum diolah, yang terkadang tidak dapat diterima oleh akal pikiran penerimanya jika belum melalui proses pengolahan.

Robert N. Anthony & John Dearden

Mereka mendefinisikan data sebagai bentuk jamak dari *datum*, yaitu unit informasi mentah yang merupakan representasi dari objek atau kejadian yang dapat diolah untuk menghasilkan informasi.

John J. Longcut

Data adalah variabel-variabel yang menggambarkan suatu keadaan yang sebenarnya, yang menjadi input bagi suatu sistem informasi.

Informasi

Raymond McLeod Jr.

Informasi adalah data yang telah diproses, atau data yang memiliki arti.

Poin Penting: Proses pengolahan adalah pembeda utama antara data dan informasi.

Jogiyanto Hartono

Informasi adalah data yang diolah menjadi bentuk yang lebih berguna dan lebih berarti bagi yang menerimanya.

Burch dan Strater

Informasi adalah pengumpulan atau pengolahan data untuk memberikan pengetahuan atau keterangan.

Perubahan Data Menjadi Informasi

Untuk memudahkan pemahaman mengenai data, secara umum dapat digunakan sebuah konsep **hirarki DIKW**. Konsep ini akan membantu kita untuk memahami perubahan data menjadi informasi.

Berikut penjelasan dari Hirarki DIKW:

1. **Data (Fakta Mentah):** Angka "40". (Ini tidak punya makna).
2. **Information (Data dengan Konteks):** "Suhu ruangan saat ini adalah 40°C". (Mulai memiliki arti).
3. **Knowledge (Informasi yang Dipahami):** "Suhu 40°C itu panas untuk manusia". (Memberikan pemahaman).
4. **Wisdom (Kebijaksanaan/Tindakan):** "Karena suhu 40°C panas, kita harus menyalakan AC". (Mengarahkan pada keputusan).

Dengan penjelasan menggunakan hirarki DIKW seperti dicontohkan di atas, dapat terlihat jelas pemahaman dari data berubah menjadi sebuah informasi.

Klasifikasi Data

Selanjutnya untuk pemahaman lebih jauh. Kita dapat mengklasifikasikan data berdasarkan beberapa sudut pandang, diantaranya:

- **Berdasarkan Sifatnya.**
 - **Kuantitatif:** Data berupa angka.
Misal : Panen mangga tahun ini mencapai 10 ton.
Penjualan sepatu merek Adidas pada bulan ini mencapai 500 pasang.
 - **Kualitatif:** Data berupa narasi/kata-kata.
Misal : Kualitas dari padi pada musim sekarang menurun.
Penjualan sepatu *sneaker* pada triwulan pertama tahun ini meningkat.
- **Berdasarkan Bentuknya.**
 - **Terstruktur:** Data dalam bentuk tabel.
Misal : File data yang terdapat dalam excel, csv atau flat file lainnya.
Table dalam database relational.
 - **Semi-Terstruktur:** File JSON atau XML.
 - **Tidak Terstruktur:** Gambar, video, suara, atau dokumen teks panjang.

Kualitas Informasi

Tidak semua informasi itu "baik". Informasi yang berkualitas harus memenuhi kriteria **ACCU**, kriteria tersebut adalah :

1. **Accurate (Akurat)** : Informasi harus bebas dari kesalahan dan tidak menyesatkan.
2. **Complete (Lengkap)** : Berisi semua fakta yang diperlukan untuk mengambil keputusan.
3. **Consistent (Konsisten)** : Informasi tidak berubah-ubah atau bertolak belakang antara satu laporan dengan lainnya.
4. **Up-to-date (Tepat Waktu)** : Informasi harus tersedia saat dibutuhkan (tidak kadaluwarsa).

Perbedaan Singkat: Data vs Informasi

Summary perbedaan antara data dan informasi tersaji dalam table di bawah ini.

Dimensi	Data	Informasi
Bentuk	Mentah (Fakta/Angka).	Matang (Laporan/Grafik).
Konteks	Belum ada.	Sudah ada.
Manfaat	Belum bisa digunakan langsung.	Sangat berguna untuk keputusan.
Contoh	Angka "100".	"Stok benih tersisa 100 kantong".



"Data adalah apa yang kita kumpulkan, Informasi adalah apa yang kita komunikasikan."

Penyimpanan Data

Dalam pengolahan data, data yang akan dan telah diolah disimpan pada suatu wadah yang biasa disebut dengan basis data atau database. Dan cara penyimpanannya pun memiliki berbagai cara agar data yang tersimpan dapat dimanfaatkan secara optimal, berikut pembahasan mengenai penyimpanan data.



Database

Secara umum **database** adalah sekumpulan data yang terorganisir secara sistematis dan disimpan secara digital dalam sistem komputer. Database dirancang agar data tersebut dapat dengan mudah diakses, dikelola, diperbarui, dan dianalisis.

Jika **Arsitektur** adalah desain kotanya, maka **Database** adalah gedung-gedung atau rumah-rumah tempat data tersebut disimpan.

Definisi Menurut Para Pakar

- **C.J. Date:** Basis data adalah koleksi data operasional yang tersimpan secara menetap (*persistent*) yang digunakan oleh sistem aplikasi dari suatu perusahaan tertentu.
- **Gordon C. Everest:** Basis data merupakan koleksi atau kumpulan data yang mekanis, terbagi (*shared*), terdefinisi secara formal, dan dikontrol secara terpusat.
- **Toni Fabbri:** Database adalah sistem file terpadu yang dirancang untuk meminimalkan pengulangan (*redundancy*) data.

Jenis Database

Pemilihan jenis database sangat bergantung pada **bentuk data** dan **tujuan penggunaannya**.

Berikut adalah beberapa jenis dan teknologi database yang paling umum digunakan saat ini:

Relational Database (*Relational Database Management System*)

Adalah jenis paling populer yang digunakan untuk menyimpan data dalam bentuk **tabel** (baris dan kolom). Antar tabel dihubungkan menggunakan kunci (*Key*) dan cocok untuk data yang terstruktur.

- **Bahasa :** Bahasa yang digunakan untuk mengakses data yang tersimpan adalah **SQL** (*Structured Query Language*). SQL merupakan bahasa standar untuk *RDBMS*.
- **Teknologi :** Contoh dari *engine* database yang menggunakan konsep *Relational* adalah Oracle Database, IBM database, PostgreSQL, MySQL, SQL Server, dan yang lainnya.
- **Kapan digunakan :** Biasanya digunakan dalam Sistem keuangan, transaksi kasir, ERP, CMS, dan yang lainnya.

NoSQL Database (Non-Relational)

NoSQL database tidak menggunakan tabel “kaku” seperti dalam database relational. Mereka lebih fleksibel dan bisa menyimpan data yang bentuknya berubah-ubah atau tidak terstruktur (seperti dokumen JSON, gambar, atau data dari media sosial).

- **Teknologi** : Contoh database yang menggunakan konsep NoSQL database diantaranya MongoDB (Dokumen), Cassandra (Kolom), Redis (Key-Value), Neo4j (Graph), dan yang lainnya.
- **Kapan digunakan**: Biasanya digunakan dalam aplikasi real-time, media sosial, atau manajemen konten web.

Cloud Database

Cloud database terinstal pada komputer lokal (on-premise), melainkan berjalan di infrastruktur penyedia layanan cloud (*Cloud Provider*).

- **Teknologi**: Contoh database cloud diantaranya Amazon RDS, Google Cloud SQL, Azure SQL Database, dan yang lainnya.
- **Kelebihan**: Skalabilitas tinggi (bisa diperbesar dengan cepat) dan kita tidak perlu memikirkan maintenance server fisik secara langsung.

Analytical Database (Data Warehouse/OLAP)

Database khusus yang dirancang untuk memproses query analitik yang sangat berat dan besar secara cepat. Biasanya digunakan sebagai dasar untuk pembuatan dashboard.

- **Teknologi**: Snowflake, Google BigQuery, Amazon Redshift.
- **Kapan digunakan**: Analisis tren penjualan tahunan, laporan performa perusahaan, atau integrasi data dari banyak departemen.

Rangkuman dari perbedaan dan penggunaan jenis database di atas tertera dalam table di bawah.

Jika Datanya...	Gunakan Jenis...	Contoh Teknologi
Teratur & Transaksional	Relational	PostgreSQL, Oracle
Berantakan & Berubah-ubah	NoSQL	MongoDB
Sangat Besar untuk Analisis	Cloud Data Warehouse	Snowflake, BigQuery
Perlu Kecepatan Super Tinggi	In-Memory	Redis

Metoda Penyimpanan Data

Macam Arsitektur dalam Penyimpanan Data

Berikut jenis dari arsitektur penyimpanan data yang berkembang dari cara tradisional ke bentuk modern.

Data Warehouse (Gudang Data Terstruktur)

Arsitektur ini adalah standar industri selama puluhan tahun. Data dari berbagai aplikasi operasional dikumpulkan, dibersihkan, dan diubah ke dalam format tetap sebelum disimpan.

- **Analogi:** Seperti perpustakaan di mana setiap buku sudah diberi label dan diletakkan di rak yang sangat spesifik.
- **Kapan digunakan:** Saat tim bisnis membutuhkan laporan bulanan yang konsisten dan akurat (seperti laporan keuangan).
- **Metode:** Menggunakan **ETL** (*Extract, Transform, Load*).

Data Lake (Penyimpanan Data Mentah)

Muncul karena kebutuhan mengolah data yang sangat besar dan bervariasi (gambar, teks, log sensor). Data disimpan apa adanya tanpa perlu diatur terlebih dahulu.

- **Analogi:** Seperti gudang besar di mana semua barang (kardus, plastik, tumpukan kayu) diletakkan begitu saja sampai nanti ada yang membutuhkannya.
- **Kapan digunakan:** Untuk kebutuhan *Data Science* dan *Big Data Analytics* yang memerlukan data mentah untuk eksperimen.
- **Metode:** Menggunakan **ELT** (*Extract, Load, Transform*).

Data Lakehouse (Modern & Terpadu)

Ini adalah tren terkini yang menggabungkan struktur dan manajemen dari *Warehouse* dengan fleksibilitas dan biaya murah dari *Lake*.

- **Kelebihan:** Anda tidak perlu memindahkan data bolak-balik antara dua sistem yang berbeda. Semuanya ada di satu tempat yang mendukung laporan bisnis sekaligus kecerdasan buatan (AI).

Medallion Architecture (Alur Kualitas Data)

Dalam training, Anda bisa menjelaskan bagaimana data "naik kelas" melalui tiga lapisan di dalam sebuah Lakehouse:

1. **Bronze (Raw):** Data kotor yang baru masuk.
2. **Silver (Cleaned):** Data yang sudah diperbaiki (misal: format tanggal disamakan, data duplikat dihapus).
3. **Gold (Curated):** Data yang sudah dihitung (misal: total penjualan per wilayah) dan siap digunakan bos/manajer.

Pendekatan Organisasional: Data Mesh

Jika audiens Anda adalah manajer atau level eksekutif, penting menyebutkan **Data Mesh**. Ini bukan sekadar teknologi, tapi cara mengatur tim.

- **Konsep:** Alih-alih satu tim IT pusat mengelola semua data, setiap departemen (Marketing, Finance, HR) bertanggung jawab atas datanya sendiri-sendiri sebagai "produk" yang bisa dipinjam oleh departemen lain.

Metoda Klasik dan Modern

Secara waktu pengembangannya, metoda penyimpanan data berkembang dari bentuk konvensional ke modern seiring dengan kebutuhan akan pengolahan data yang ditunjang dengan perkembangan teknologi. Maka dari itu muncullah istilah metoda klasik dan modern. Untuk itu alangkah baiknya kita mengenal tokoh-tokoh dibalik perkembangan metoda tersebut.

Tokoh dalam Data Architecture

Dalam dunia *Data Warehouse* dan *Data Architecture*, **Bill Inmon** dan **Ralph Kimball** adalah dua tokoh "Legenda" yang pemikirannya sering kali menjadi bahan perdebatan klasik. Sementara itu, **Medallion Architecture** merupakan konsep yang lahir dari era modern.

Bill Inmon (William H. Inmon)

Bill Inmon dikenal sebagai orang pertama yang mendefinisikan konsep *Data Warehouse* secara formal. Inmon juga dikenal sebagai *Bapak Data Warehouse*.

- **Definisi:** Menurut Inmon data adalah subjek yang berorientasi, terintegrasi, memiliki dimensi waktu, dan tidak mudah berubah untuk mendukung pengambilan keputusan manajemen.
- **Pendekatan (Top-Down):** Inmon menyarankan agar data dari seluruh perusahaan dikumpulkan dulu ke satu tempat pusat yang sangat rapi dan terstandarisasi




(Normalized/ERD), baru kemudian disebar ke departemen-departemen kecil. Dari atas disebar ke bawah/ Top-Down.

- **Analogi:** Seperti membangun perpustakaan pusat kota terlebih dahulu sebelum membuka taman bacaan di tiap kelurahan.

Ralph Kimball

Jika Inmon fokus pada struktur pusat, **Ralph Kimball** fokus pada kecepatan dan kemudahan pengguna bisnis. Dikenal sebagai pencetus dari *Dimensional Modelling*.



- **Definisi:** Menurut Kimball data bukan hanya catatan, tapi alat untuk membantu bisnis menjawab pertanyaan dengan cepat.
- **Pendekatan (Bottom-Up):** Kimball memperkenalkan *Dimensional Modeling (Star Schema)*. Menurutnya, data harus langsung disusun berdasarkan kebutuhan departemen (misal: Penjualan, HR) agar mudah dianalisis.
- **Analogi:** Seperti langsung membangun toko-toko kelontong yang lengkap di tiap lingkungan agar warga tidak perlu jauh-jauh ke pusat kota untuk belanja.

Medallion Architecture

Berbeda dengan tokoh perorangan di atas, **Medallion Architecture** (Bronze, Silver, Gold) secara resmi diperkenalkan dan dipopulerkan oleh perusahaan bernama **Databricks**.

- **Latar Belakang:** Konsep ini muncul seiring dengan lahirnya teknologi **Delta Lake**.
- **Tujuan:** Untuk memberikan struktur dan jaminan kualitas pada **Data Lake** (yang seringkali berantakan dan disebut "Data Swamp").
- **Kontribusi:** Mereka menciptakan standar industri tentang bagaimana data "mentah" diolah secara bertahap hingga menjadi "emas" (siap pakai). Saat ini, hampir semua penyedia layanan *cloud* (seperti Microsoft Azure) mengadopsi kerangka kerja ini.

Rangkuman mengenai Arsitektur Penyimpanan Data tercantum pada table di bawah.

Pencetus	Peran	Warisan Utama
Bill Inmon	<i>Father of Data Warehouse</i>	Pendekatan Terpusat & Terstruktur (Top-Down).
Ralph Kimball	<i>Pioneer of Business Intelligence</i>	Dimensional Modeling (Star Schema).
Databricks	<i>Modern Architecture Innovator</i>	Medallion Architecture (Bronze, Silver, Gold).

Perbandingan Data Warehouse Vs Medallion

Berikut perbandingan antara konsep data warehouse dengan medallion secara singkat.

Data Warehouse (DWH): Fokus pada Struktur dan Hubungan

Data Warehouse adalah arsitektur yang sangat teratur. Yang mana dalam arsitektur ini difokuskan bagaimana table-table yang ada terhubung dengan teratur dan diharapkan dapat menghasilkan performance yang cepat ketika data diambil / di-query.

Komponen Utama dalam DWH:

- **Fact Table** : Berisi angka atau ukuran bisnis (misal: jumlah penjualan, harga, kuantitas).
- **Dimension Table** : Berisi keterangan atau atribut (misal: nama produk, kategori, lokasi toko, tanggal).

Contoh Kasus: Penjualan Ritel

Di dalam sebuah Data Warehouse, data diatur dengan menggunakan *Snowflake Schema* atau *Star Schema*.

- **Pusat (Fact)**: Table fact menjadi table “pusat” untuk menampung data transaksi.
- **Cabang (Dimension)**: Table dimensi menjadi table penampung atribut dari data yang ada yang menjadikan konteks untuk masing-masing data yang tersimpan dalam table fact.

Karakteristik Utama:

- **Skema Tetap**: Struktur tabel harus didefinisikan di awal sebelum data masuk.
- **Penyimpanan Efisien**: Menggunakan teknik normalisasi untuk mengurangi redundansi data.

Medallion Architecture: Fokus pada Kualitas dan Alur

Berbeda dengan DWH yang bicara soal “bentuk tabel”, Medallion Architecture bicara soal “perjalanan data” dari “kotor” menjadi “bersih”. Medallion sangat populer dalam implementasi data engineering modern dengan menggunakan teknologi seperti Snowflake, Python, dan dbt.

Berikut adalah tahapan “naik kelas” atau *layering* data dalam Medallion Architecture:

A. Bronze Layer (Raw Data)

- **Kondisi**: Data mentah apa adanya dari sumber (Database operasional, Excel, API).
- **Isi**: Masih ada data duplikat, format tanggal berantakan, atau nilai yang kosong (*null*).

- **Tujuan:** Sebagai histori cadangan jika sewaktu-waktu perlu memproses ulang data dari awal.

B. Silver Layer (Cleansed & Filtered)

- **Proses:** Data dibersihkan menggunakan Python atau SQL.
- **Tindakan:** Menghapus duplikat, standarisasi format (misal: semua nomor telepon diawali +62), dan validasi tipe data.
- **Tujuan:** Menyediakan sumber data yang "terpercaya" bagi para Data Analyst untuk eksplorasi.

C. Gold Layer (Curated / Business Ready)

- **Proses:** Data dari Silver diagregasi atau dihitung sesuai kebutuhan bisnis.
- **Isi:** Tabel yang sudah jadi (misal: Tabel Performa Sales Bulanan).
- **Tujuan:** Siap dikonsumsi langsung oleh dasbor visualisasi (seperti Tableau/PowerBI) atau laporan eksekutif.

Table perbandingan antara Hub-and-spoke vs Medallion

Fitur	Data Warehouse (DWH)	Medallion Architecture
Fokus Utama	Bagaimana data disimpan dan dihubungkan (Struktur).	Bagaimana kualitas data ditingkatkan (Alur/Proses).
Pendekatan	Schema-on-write (Aturan ketat di awal).	Incremental improvement (Makin ke ujung makin bersih).
Analogi	Rak buku yang sudah dikategorikan rapi.	Proses penyaringan air dari air sungai hingga jadi air mineral siap minum.
Teknologi Umum	Oracle, Snowflake, SQL Server.	Databricks, Snowflake dengan dbt/Airflow.